Aprendizaje No Supervisado

Ejercicio 1 — Europa: PCA, Regla de Oja y Red de Kohonen

TP4 – Sistemas de Inteligencia Artificial

10 de mayo de 2026

ITBA — 2026

El problema

Dataset: `europe.csv` — 28 paises europeos $\times$ 7 variables numericas.

- Area (km^2)
- GDP (PIB per capita)
- Inflation (%)
- Life.expect (anios)
- Military (presupuesto)
- Pop.growth (%)
- Unemployment (%)

Objetivo: descubrir estructura — relaciones entre variables, agrupamiento de paises — sin etiquetas.

Tres tecnicas, una historia:

- **PCA (libreria)**: reduccion de dimensionalidad por autovalores.
- **Oja**: PC1 iterativa, sin resolver autovalores explicitamente.
- **Kohonen / SOM**: mapeo a grilla 2D conservando topologia.

Las escalas son muy distintas

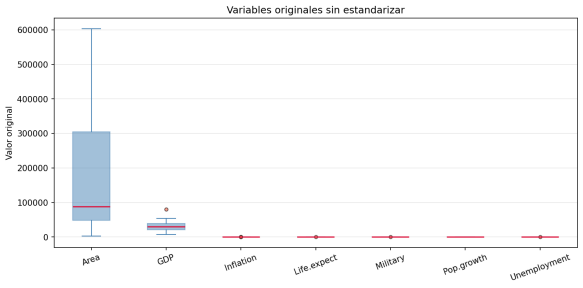

Sin estandarizar:

- `Area` domina ($\sim 10^5$).
- `GDP` en otro orden de magnitud ($\sim 10^4$).
- `Inflation`, `Life.expect`, `Military`, `Pop.growth`, `Unemployment`: $\sim 10^0$–10^1.

Consecuencia: la varianza esta dominada por la escala, no por la informacion. Aplicar PCA o medir distancias asi seria enganioso.

PCA con libreria

Estandarizacion

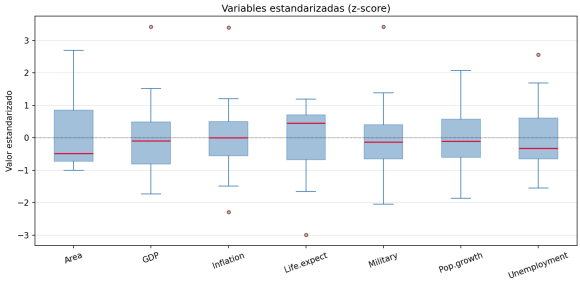

Z-score:

$$\tilde{X}_j = \frac{X_j - \bar{X}_j}{s_j}$$

Cada variable queda con media 0 y varianza 1. Todas las variables son ahora comparables.

Equivalencia clave: aplicar PCA sobre los datos estandarizados $\equiv$ aplicar PCA sobre la matriz de correlacion (no de covarianza).

Hay redundancia: tiene sentido hacer PCA

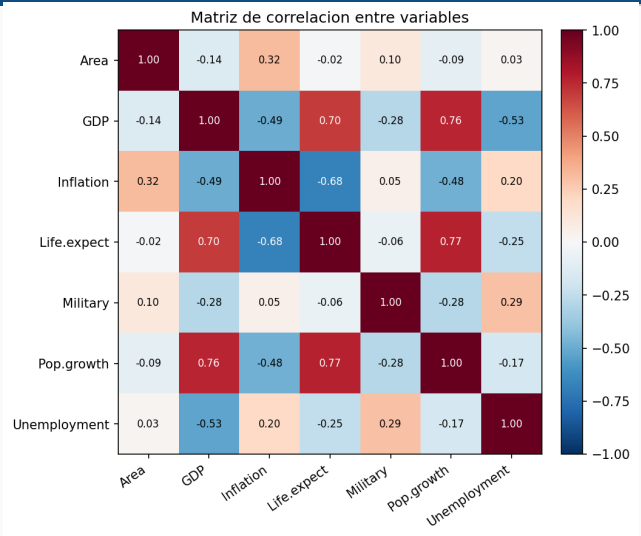

Varias variables estan fuertemente correlacionadas:

- `GDP` y `Life.expect` ($r = +0{,}74$).
- `Inflation` con varias (r negativos).
- `Pop.growth` con `GDP` y `Life.expect` ($r > 0{,}4$).

Si no hubiera correlacion, no tendria sentido hacer PCA.

Cuanta informacion explica cada componente

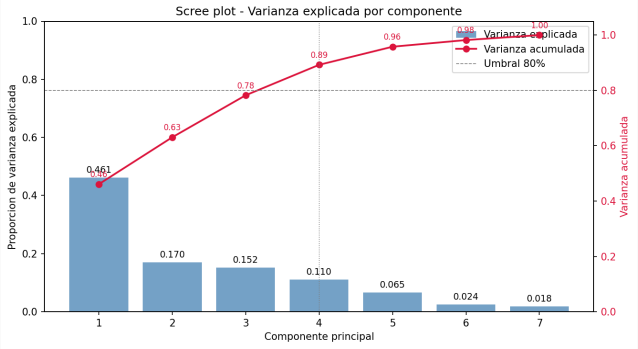

- **PC1**: 46.1 % de la varianza.
- **PC2**: 17.0 %.
- **PC3**: 15.2 %.
- **PC1+PC2+PC3**: 78.3 %.
- Hace falta una **4ta** componente para cruzar el 80 %.

Con 2 componentes ya capturamos ∼63 % — suficiente para visualizar.

Cargas: que representa cada componente

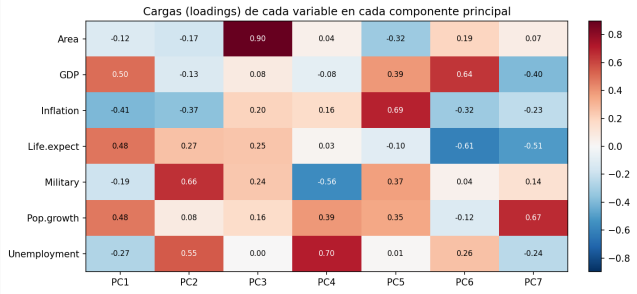

PC1 – "Desarrollo"

+`GDP`, +`Life.expect`, +`Pop.growth`, −`Inflation`, −`Unemployment`.

PC2 – "Crisis"

+`Military`, +`Unemployment` vs −`Inflation`.

Captura Grecia / Espania / Croacia.

PC3 – "Tamanio"

Casi solo `Area` (+0,90).

Biplot PC1 vs PC2: agrupamientos

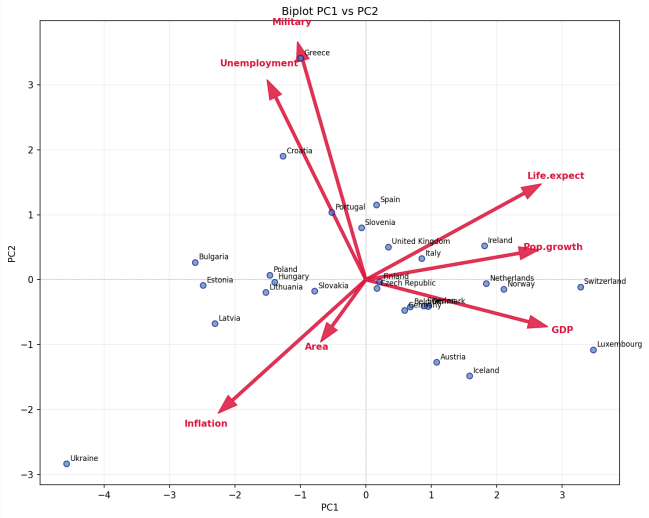

Ranking de paises segun PC1

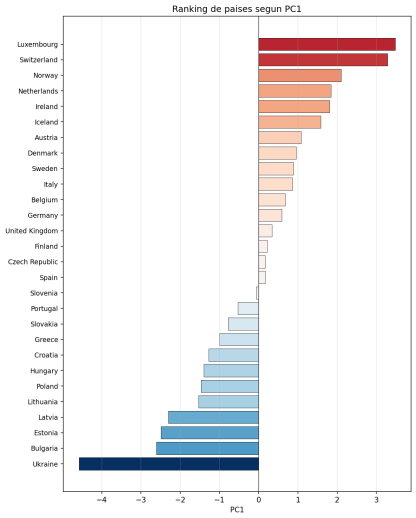

PC1 ordena los paises por un **indice de desarrollo / bienestar**:

- **Top**: Luxembourg, Switzerland, Norway, Netherlands, Ireland.
- **Centro**: Italy, Belgium, Germany, UK.
- **Bottom**: Ukraine, Bulgaria, Estonia, Latvia.

Es la nueva variable sintetica que mejor diferencia los paises del dataset.

PC2: dimension complementaria

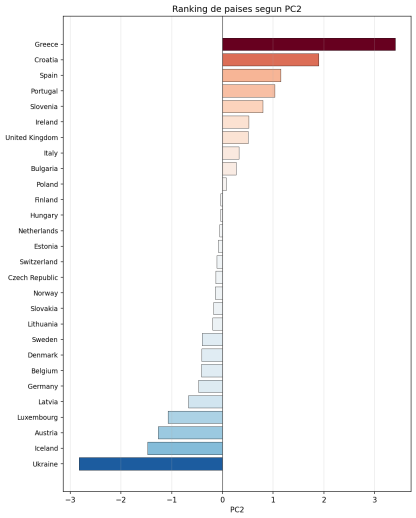

PC2 captura un eje **ortogonal** a PC1:

- Arriba: Grecia, Croacia, Spain — alta inestabilidad (Military / Unemployment).
- Abajo: Luxemburgo, Iceland, Austria — estabilidad fiscal.

Algunos paises con PC1 medio (Spain) se separan claramente en PC2.

Regla de Oja

Calcular PC1 sin resolver autovalores

Idea: un perceptron lineal con una neurona y la regla de actualizacion

$$\Delta w = \eta\, y\,(x - y\, w), \quad y = w^T x$$

Por que funciona:

- Hebbiano puro hace que $\|w\| \to \infty$.
- El termino $-y\, w$ normaliza implicitamente: $\|w\| \to 1$.
- w converge al autovector del mayor autovalor de la matriz de correlacion — es la PC1.

Hiperparametros:

- Inicializacion: $w_0 \sim \mathcal{U}(0, 1)$, normalizada.
- $\eta = 10^{-3}$ constante.
- Epocas: 200.
- Datos: estandarizados (media 0, std 1).

Recomendaciones teoricas: estandarizar siempre y usar $\eta \leq 0{,}5$ o 10^{-3} pequenio.

Convergencia: $\|w\| \to 1$ y $w \to$ PC1

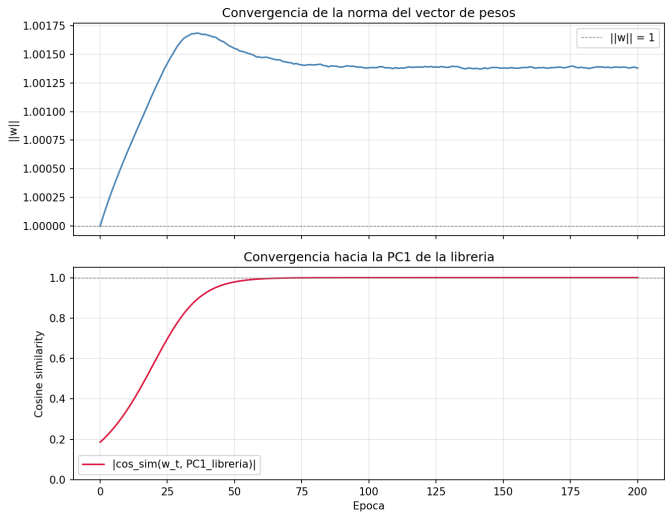

Evolucion de las componentes de w

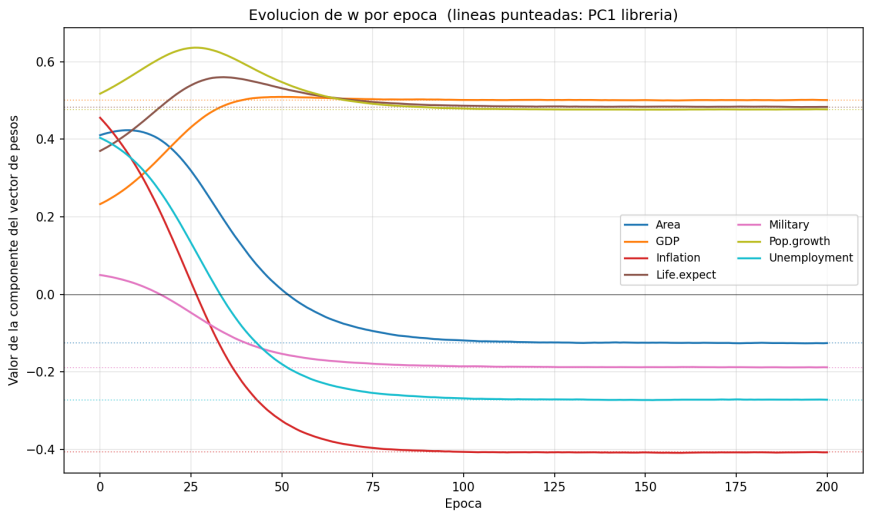

Comparacion con la libreria: cargas

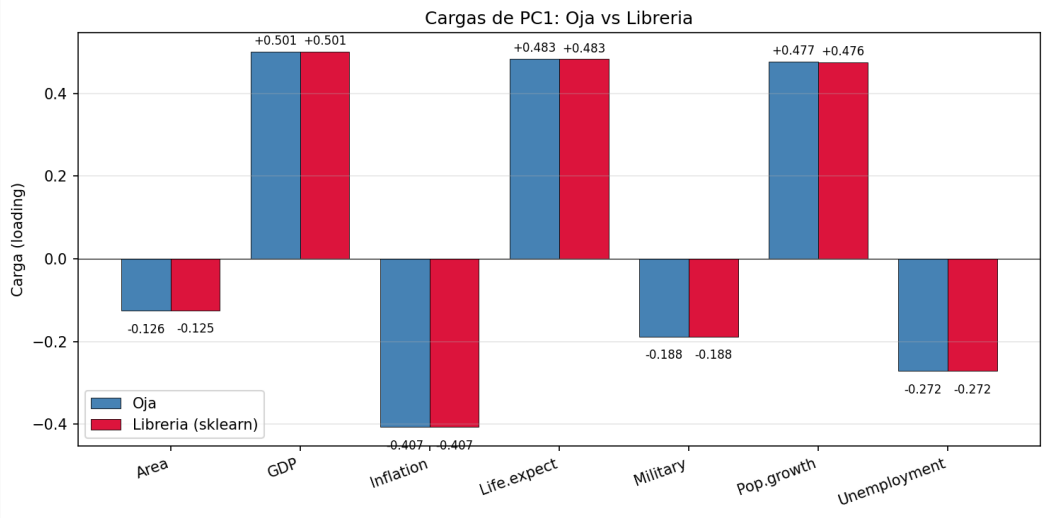

Comparacion: scores por pais

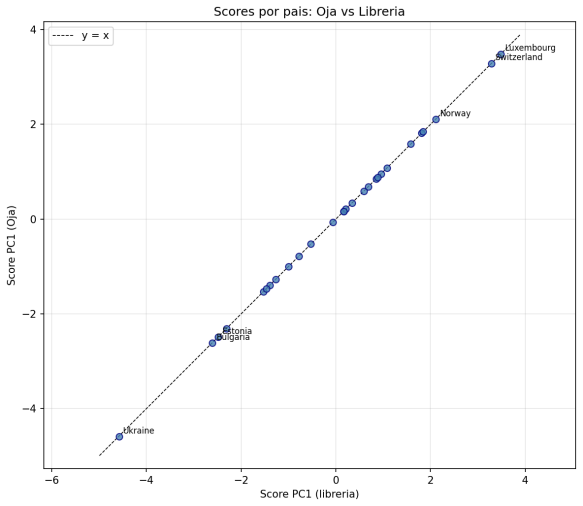

Metricas de coincidencia:

- Cosine similarity cargas: $+0{,}99999943$.
- Max abs error cargas: $0{,}00126$.
- RMSE cargas: $0{,}00066$.
- Pearson scores: $+0{,}99999986$.
- Spearman ranking: $+1{,}0$.
- $\|w_{\text{Oja}}\| = 1{,}0014$.

Oja recupera la PC1 con error numerico despreciable, sin haber resuelto un solo problema de autovalores.

Red de Kohonen / SOM

Mapeo no-lineal a una grilla 2D

Arquitectura: grilla $k \times k$ de neuronas, cada una con peso $W_j \in \mathbb{R}^n$.

Algoritmo competitivo:

1. Para cada muestra x, encontrar la neurona ganadora $\hat{k} = \arg\min_j \|x - W_j\|$.
2. Actualizar a las neuronas dentro del radio $R(t)$ en la grilla:

$$W_j \leftarrow W_j + \eta(t)\,(x - W_j)$$

3. $\eta(t)$ y $R(t)$ decrecen con el tiempo.

Hiperparametros:

- Grilla 4×4 (16 neuronas; $\sim$2 paises/neurona).
- $\eta(t)$: 0,5 $\rightarrow$ 0,01 lineal.
- $R(t)$: 2 $\rightarrow$ 1 lineal.
- 500 epocas (14000 iteraciones).
- Inicializacion: muestras del dataset.
- Distancia: euclidea.

Convergencia

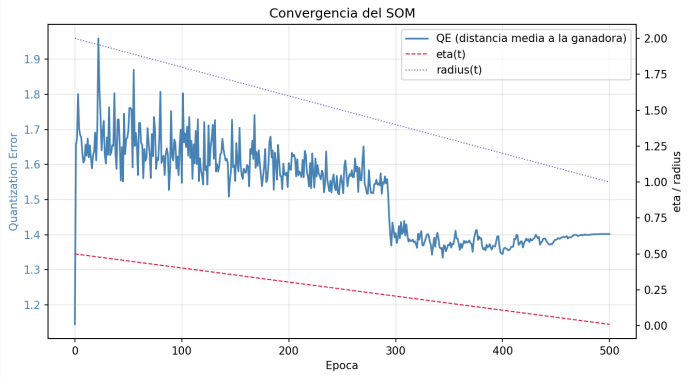

Lectura:

- Las primeras epocas son "ruidosas": el radio amplio mezcla todo.
- Hacia la epoca 290 el radio se acerca a 1 — transicion de fase: solo se actualizan ganadora y vecinos directos.
- QE se estabiliza ($\sigma_{\text{rel}} = 4{,}8 \times 10^{-4}$ en las ultimas 20 epocas).

Mapa de paises

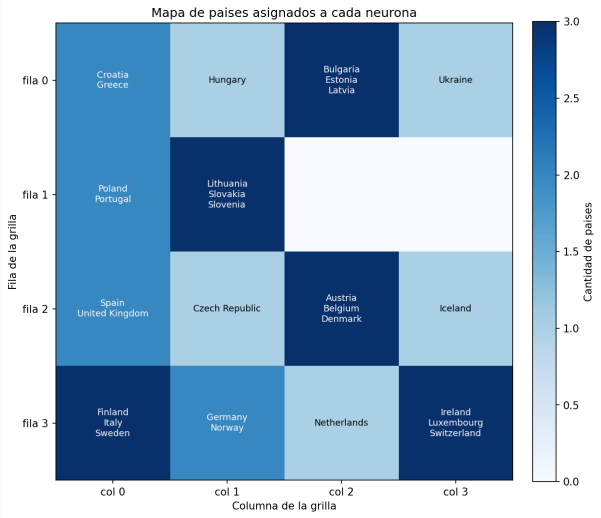

Matriz U: fronteras entre clusters

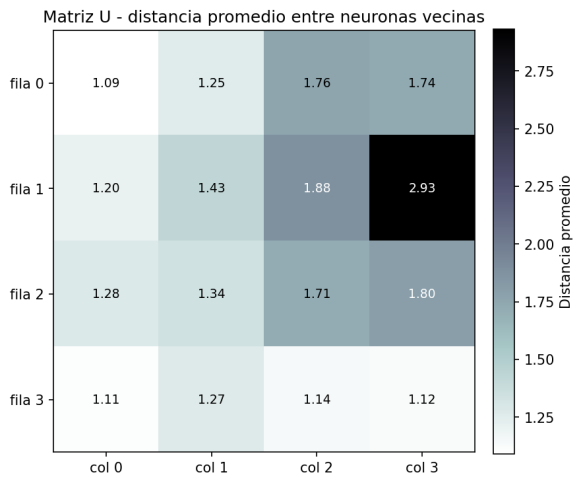

Distancia promedio de cada neurona a sus 8 vecinos:

- **Claro**: neuronas similares (clusters).
- **Oscuro**: fronteras.

La neurona en `(1,3)` es la frontera entre Ucrania (esquina (0,3)) y el resto — distancia 2.93 — es el outlier mas marcado del dataset.

Cantidad de paises por neurona

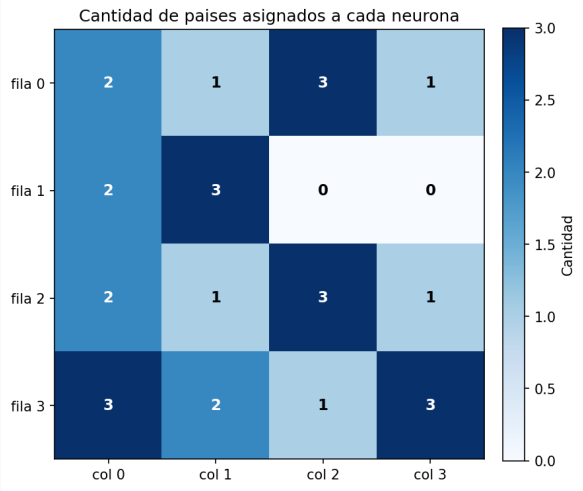

- 14 de 16 neuronas reciben al menos un pais.
- Maximo: 3 paises (varias neuronas).
- 2 neuronas vacias en la zona-frontera (col 2–3, fila 1) — consistente con la Matriz U.

No hay neuronas "muertas" lejos de los datos: la inicializacion con muestras evita ese problema.

Mapas por variable: que significa cada zona

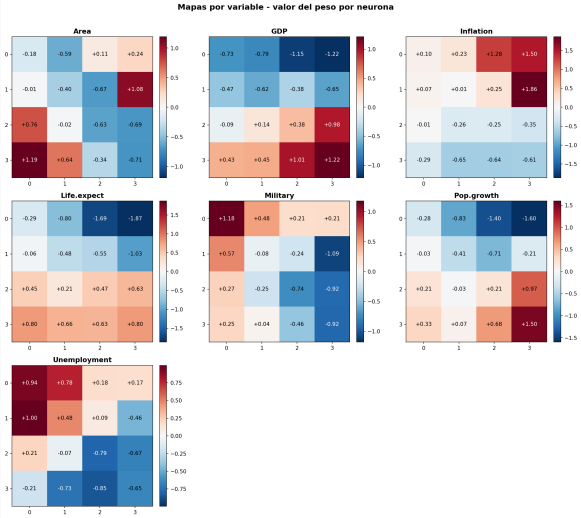

Interpretacion del mapa

- **Fila 3 (abajo)** — alta `GDP`, alta `Life.expect`: Finland, Italy, Sweden, Germany, Norway, Netherlands, Ireland, Luxembourg, Switzerland.
- **Fila 0 (arriba)** — baja `GDP`, alta `Inflation`, alta `Unemployment`: Croatia, Greece, Hungary, Bulgaria, Estonia, Latvia, Ukraine.
- **Columna 0 (izquierda)** — alta `Military`: Grecia, Croacia, Spain.
- **Columna 3 esquina (0,3)** — aislada por la Matriz U: Ucrania, −PIB, +inflacion extrema (8 %).

Los ejes ortogonales del SOM **coinciden con los ejes PC1 y PC2**:

- Vertical $\approx$ PC1 (desarrollo).
- Horizontal $\approx$ PC2 (crisis fiscal).

Conclusiones

Que aprendimos del EJ1

- **PC1 captura "desarrollo / bienestar"** — combinacion ponderada de +GDP, +Life.expect, +Pop.growth, −Inflation, −Unemployment. Explica el 46 % de la varianza.
- **Oja recupera PC1** sin resolver autovalores explicitamente: cosine similarity 0,99999943, ranking de paises identico al de la libreria. Validacion total de la teoria iterativa.
- **El SOM produce un mapa topologico consistente con PCA**: paises del bloque oeste-norte vs este-sur, con Ucrania aislada como outlier. La Matriz U evidencia que el SOM aprende fronteras de cluster, no solo prototipos.
- Las tres tecnicas convergen al mismo relato geopolitico: hay un eje principal de desarrollo y un eje secundario de crisis fiscal.

Gracias.

Codigo + figuras en el repositorio.