Aprendizaje No Supervisado

Ejercicio 1 — Europa: PCA, Regla de Oja y Red de Kohonen

TP4 – Sistemas de Inteligencia Artificial

10 de mayo de 2026

ITBA — 2026

El problema

Dataset: `europe.csv` — 28 paises europeos $\times$ 7 variables numericas.

- Area (km^2)
- GDP (PIB per capita)
- Inflation (%)
- Life.expect (anios)
- Military (presupuesto)
- Pop.growth (%)
- Unemployment (%)

Objetivo: descubrir estructura — relaciones entre variables, agrupamiento de paises — sin etiquetas.

Tres tecnicas, una historia:

- **PCA (libreria)**: reduccion de dimensionalidad por autovalores.
- **Oja**: PC1 iterativa, sin resolver autovalores explicitamente.
- **Kohonen / SOM**: mapeo a grilla 2D conservando topologia.

Las escalas son muy distintas

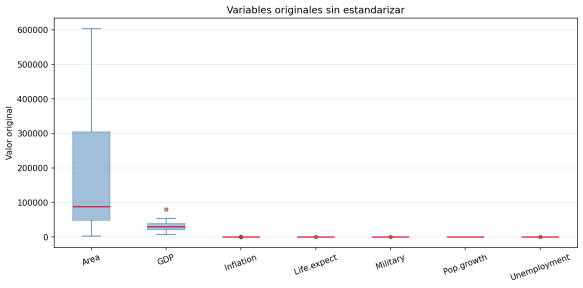

Sin estandarizar:

- `Area` domina ($\sim 10^5$).
- `GDP` en otro orden de magnitud ($\sim 10^4$).
- `Inflation`, `Life.expect`, `Military`, `Pop.growth`, `Unemployment`: $\sim 10^0$–10^1.

Consecuencia: la varianza esta dominada por la escala, no por la informacion. Aplicar PCA o medir distancias asi seria enganioso.

PCA con libreria

Estandarizacion

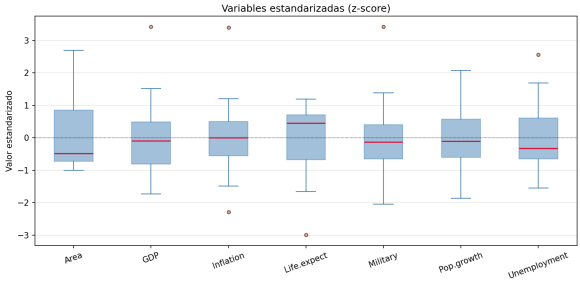

Z-score:

$$\tilde{X}_j = \frac{X_j - \bar{X}_j}{s_j}$$

Cada variable queda con media 0 y varianza 1. Todas las variables son ahora comparables.

Equivalencia clave: aplicar PCA sobre los datos estandarizados $\equiv$ aplicar PCA sobre la matriz de correlacion (no de covarianza).

Hay redundancia: tiene sentido hacer PCA

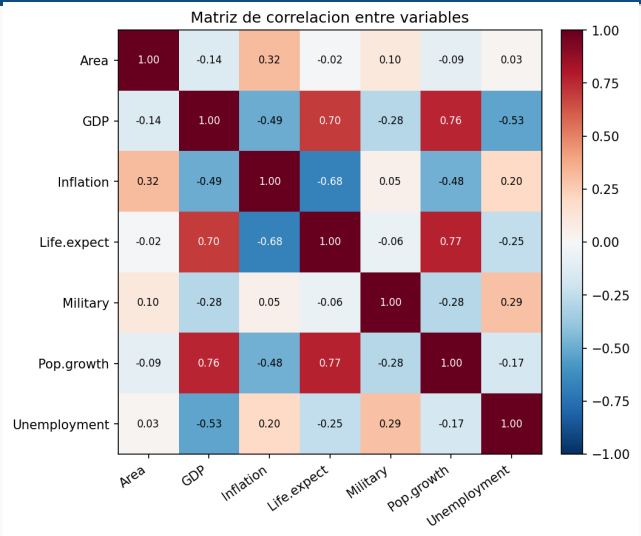

Varias variables estan fuertemente correlacionadas:

- `GDP` y `Life.expect` ($r = +0{,}74$).
- `Inflation` con varias (r negativos).
- `Pop.growth` con `GDP` y `Life.expect` ($r > 0{,}4$).

Si no hubiera correlacion, no tendria sentido hacer PCA.

Cuanta informacion explica cada componente

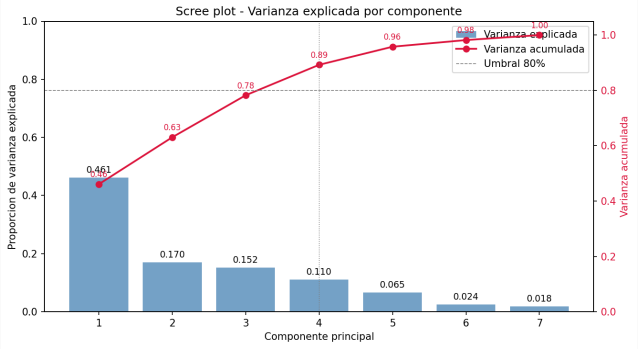

- **PC1**: 46.1 % de la varianza.
- **PC2**: 17.0 %.
- **PC3**: 15.2 %.
- **PC1+PC2+PC3**: 78.3 %.
- Hace falta una **4ta** componente para cruzar el 80 %.

Con 2 componentes ya capturamos ∼63 % — suficiente para visualizar.

Cargas: que representa cada componente

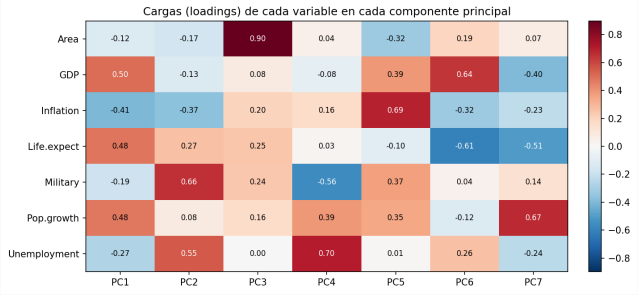

PC1 – "Desarrollo"

+`GDP`, +`Life.expect`, +`Pop.growth`, −`Inflation`, −`Unemployment`.

PC2 – "Crisis"

+`Military`, +`Unemployment` vs −`Inflation`.

Captura Grecia / Espania / Croacia.

PC3 – "Tamanio"

Casi solo `Area` (+0,90).

Biplot PC1 vs PC2: agrupamientos

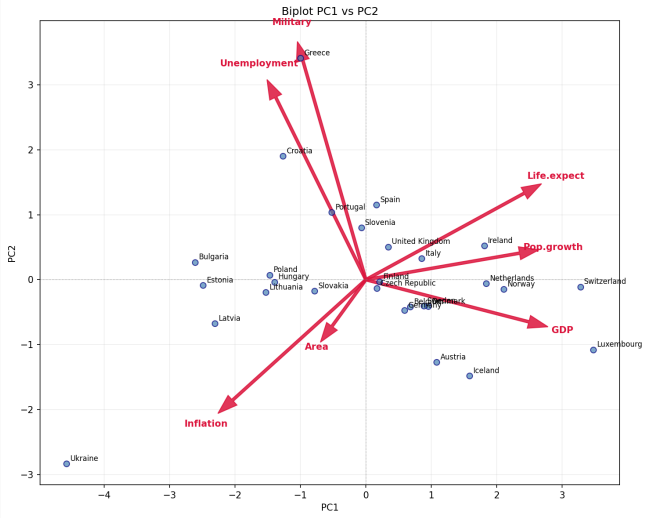

Ranking de paises segun PC1

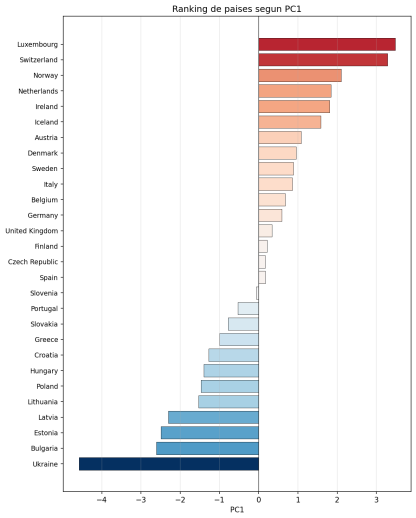

PC1 ordena los paises por un **indice de desarrollo / bienestar**:

- **Top**: Luxembourg, Switzerland, Norway, Netherlands, Ireland.
- **Centro**: Italy, Belgium, Germany, UK.
- **Bottom**: Ukraine, Bulgaria, Estonia, Latvia.

Es la nueva variable sintetica que mejor diferencia los paises del dataset.

PC2: dimension complementaria

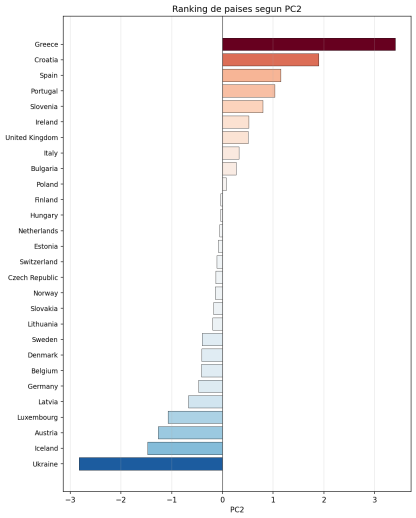

PC2 captura un eje **ortogonal** a PC1:

- Arriba: Grecia, Croacia, Spain — alta inestabilidad (Military / Unemployment).
- Abajo: Luxemburgo, Iceland, Austria — estabilidad fiscal.

Algunos paises con PC1 medio (Spain) se separan claramente en PC2.

Regla de Oja

Calcular PC1 sin resolver autovalores

Idea: un perceptron lineal con una neurona y la regla de actualizacion

$$\Delta w = \eta\, y\,(x - y\, w), \quad y = w^T x$$

Por que funciona:

- Hebbiano puro hace que $\|w\| \to \infty$.
- El termino $-y\, w$ normaliza implicitamente: $\|w\| \to 1$.
- w converge al autovector del mayor autovalor de la matriz de correlacion — es la PC1.

Hiperparametros:

- Inicializacion: $w_0 \sim \mathcal{U}(0, 1)$, normalizada.
- $\eta = 10^{-3}$ constante.
- Epocas: 200.
- Datos: estandarizados (media 0, std 1).

Recomendaciones teoricas: estandarizar siempre y usar $\eta \leq 0{,}5$ o 10^{-3} pequenio.

Convergencia: $\|w\| \to 1$ y $w \to$ PC1

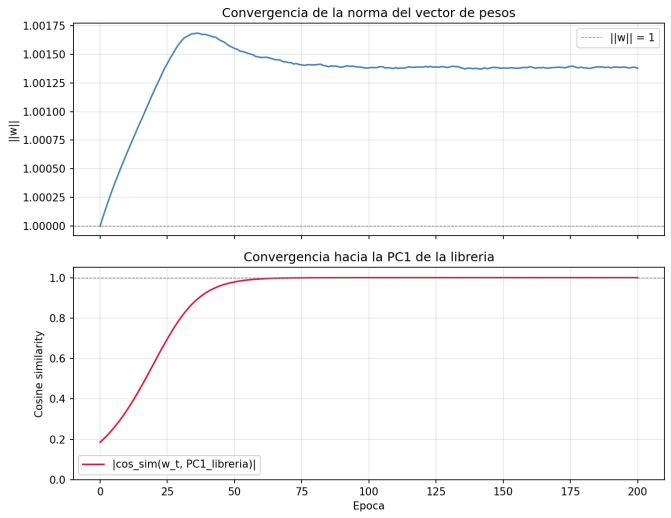

Evolucion de las componentes de w

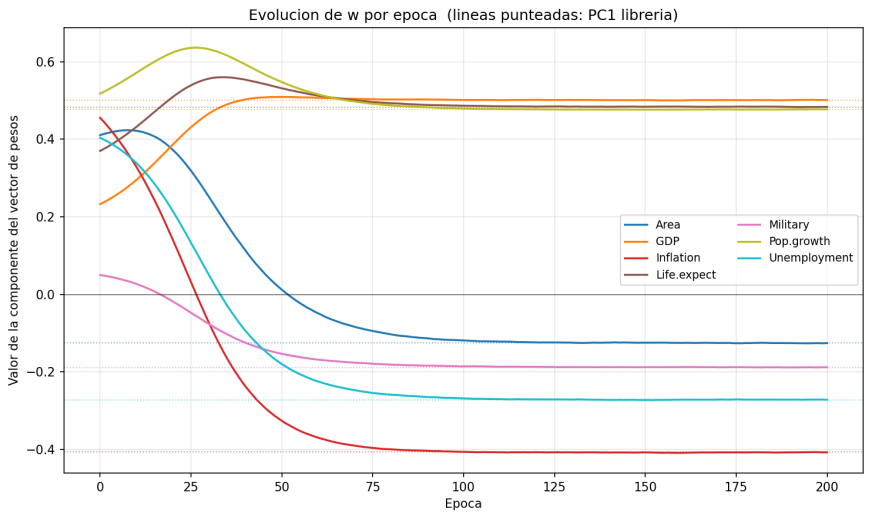

Comparacion con la libreria: cargas

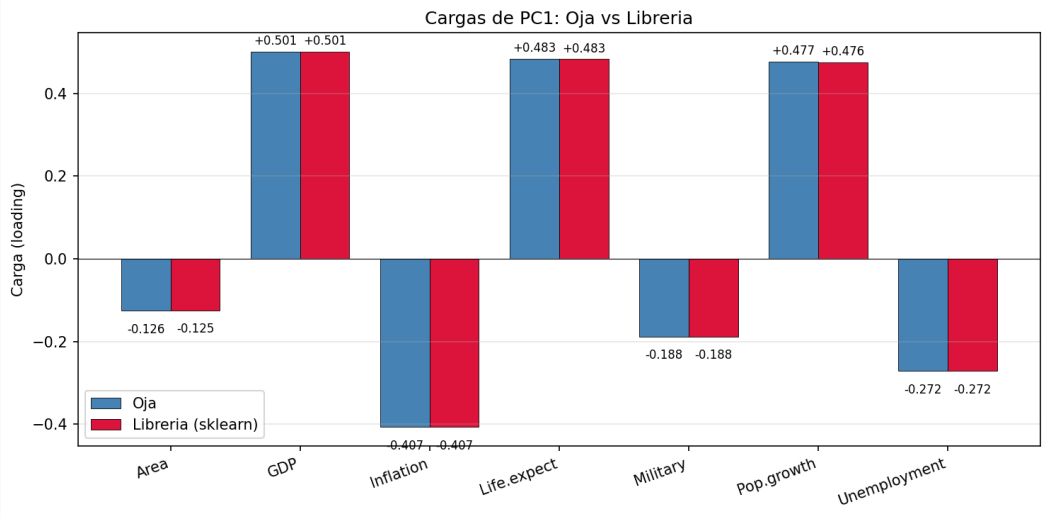

Comparacion: scores por pais

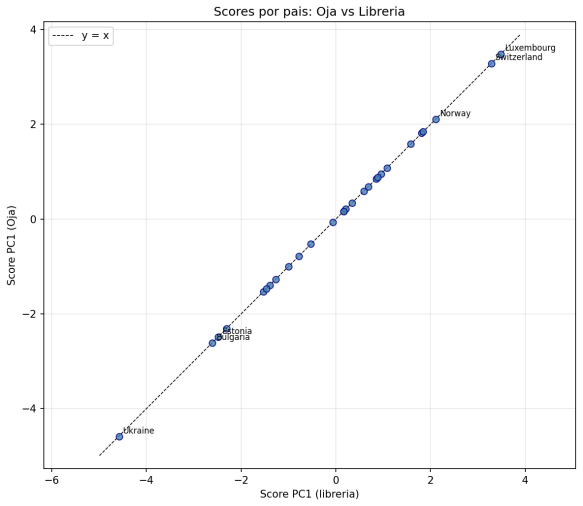

Metricas de coincidencia:

- Cosine similarity cargas: $+0{,}99999943$.
- Max abs error cargas: $0{,}00126$.
- RMSE cargas: $0{,}00066$.
- Pearson scores: $+0{,}99999986$.
- Spearman ranking: $+1{,}0$.
- $\|w_{\text{Oja}}\| = 1{,}0014$.

Oja recupera la PC1 con error numerico despreciable, sin haber resuelto un solo problema de autovalores.

Triangulacion: tres caminos, una misma PC1

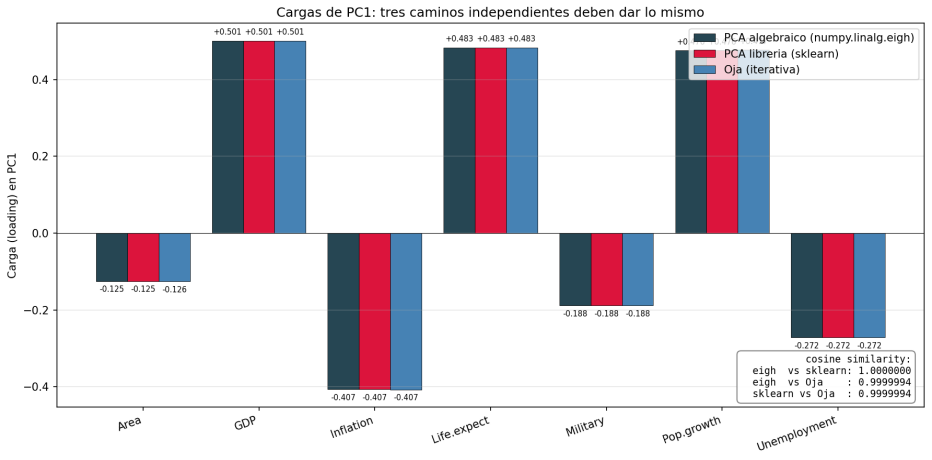

Tres metodos independientes coinciden: `eigh` sobre la matriz de correlacion, SVD de `sklearn.PCA` y red neuronal Oja. eigh y sklearn son identicos a precision de maquina; Oja aporta un error $\sim 10^{-3}$ propio de la iteracion.

Red de Kohonen / SOM

Mapeo no-lineal a una grilla 2D

Arquitectura: grilla $k \times k$ de neuronas, cada una con peso $W_j \in \mathbb{R}^n$.

Algoritmo competitivo:

1. Para cada muestra x, encontrar la neurona ganadora $\hat{k} = \arg\min_j \|x - W_j\|$.
2. Actualizar a las neuronas dentro del radio $R(t)$ en la grilla:

$$W_j \leftarrow W_j + \eta(t)\,(x - W_j)$$

3. $\eta(t)$ y $R(t)$ decrecen con el tiempo.

Hiperparametros:

- Grilla 4×4 (16 neuronas; $\sim$2 paises/neurona).
- $\eta(t)$: 0,5 $\rightarrow$ 0,01 lineal.
- $R(t)$: 2 $\rightarrow$ 1 lineal.
- 500 epocas (14000 iteraciones).
- Inicializacion: muestras del dataset.
- Distancia: euclidea.

Convergencia

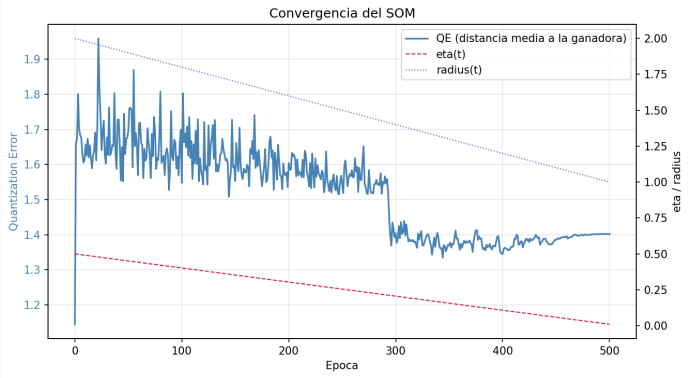

Lectura:

- Las primeras epocas son "ruidosas": el radio amplio mezcla todo.
- Hacia la epoca 290 el radio se acerca a 1 — transicion de fase: solo se actualizan ganadora y vecinos directos.
- QE se estabiliza ($\sigma_{\text{rel}} = 4{,}8 \times 10^{-4}$ en las ultimas 20 epocas).

Mapa de paises

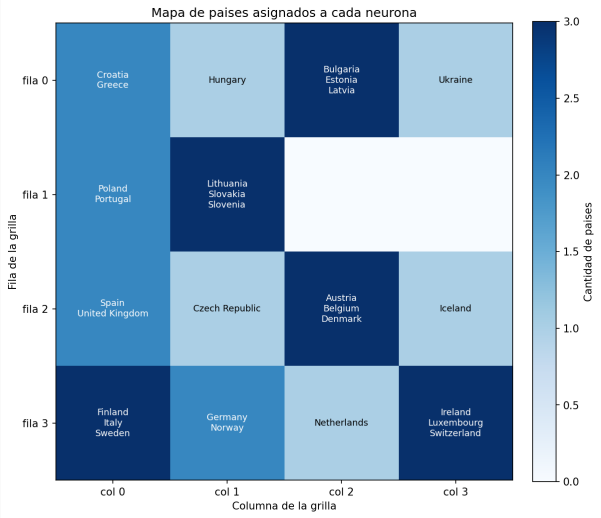

Matriz U: fronteras entre clusters

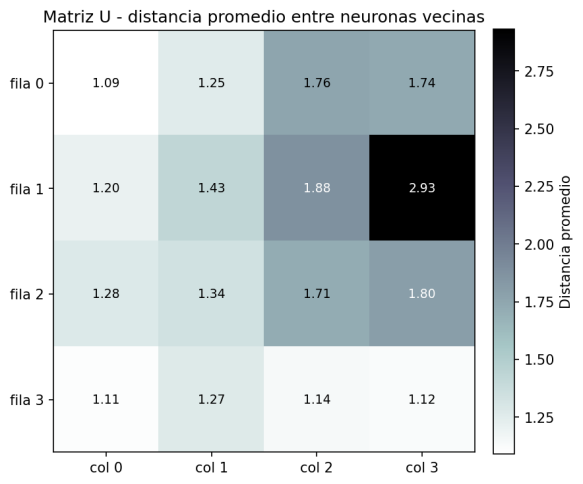

Distancia promedio de cada neurona a sus 8 vecinos:

- **Claro**: neuronas similares (clusters).
- **Oscuro**: fronteras.

La neurona en `(1,3)` es la frontera entre Ucrania (esquina (0,3)) y el resto — distancia 2.93 — es el outlier mas marcado del dataset.

Cantidad de paises por neurona

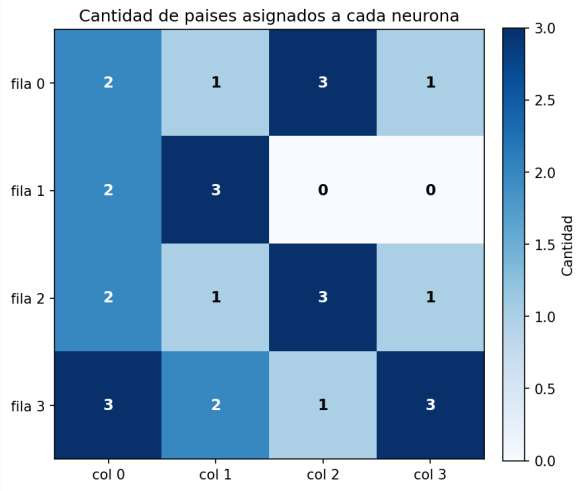

- 14 de 16 neuronas reciben al menos un pais.
- Maximo: 3 paises (varias neuronas).
- 2 neuronas vacias en la zona-frontera (col 2–3, fila 1) — consistente con la Matriz U.

No hay neuronas "muertas" lejos de los datos: la inicializacion con muestras evita ese problema.

Mapas por variable: que significa cada zona

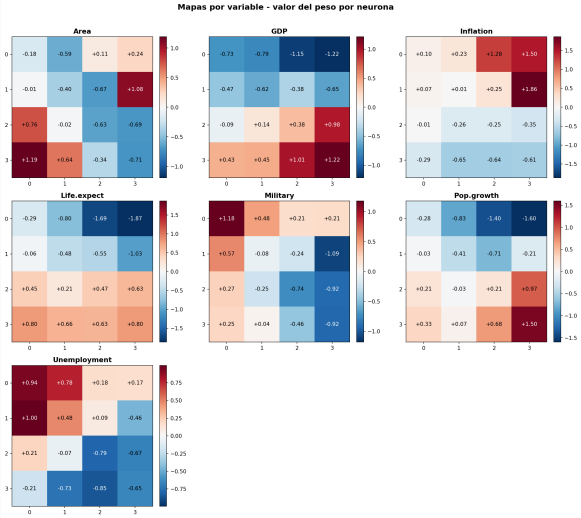

Perfil promedio por cluster (valores originales)

Cada fila es una neurona activa. Las celdas muestran el valor original (no estandarizado); el color es el z-score respecto al promedio entre clusters (rojo = alto, azul = bajo).

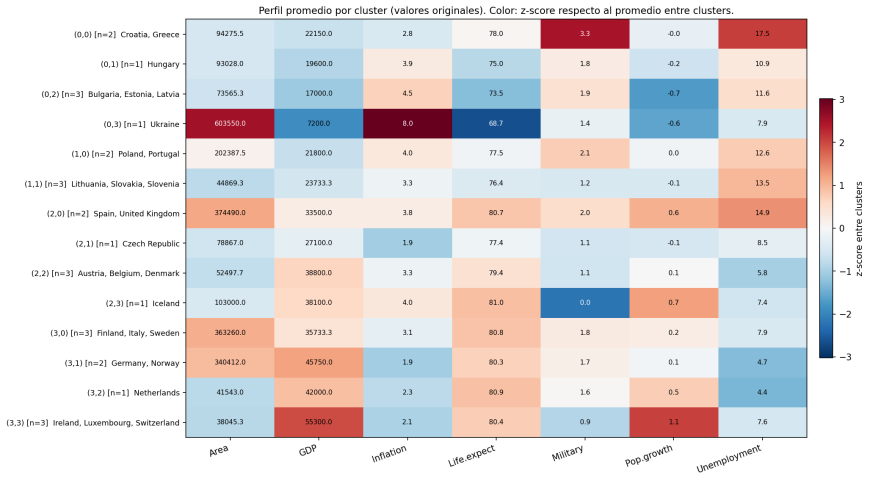

Por que son parecidos los paises de cada celda

- **(3,3) Ireland, Luxembourg, Switzerland**: GDP ∼55300 USD (top), `Life.expect` 80.4, `Unemployment` 7.6, `Pop.growth` +1,0. Mismo perfil: economias muy ricas, demograficamente saludables.
- **(0,2) Bulgaria, Estonia, Latvia**: GDP ∼17000 USD, `Inflation` 4.5 %, `Pop.growth` −0,7. Ex-orbita sovietica con encogimiento poblacional.
- **(0,0) Croatia, Greece**: GDP ∼22150, `Unemployment` 17.5 %, `Military` alto. Crisis fiscal mediterranea.
- **(0,3) Ukraine**: GDP 7200, `Inflation` 8 %, `Life.expect` 68.7. Outlier extremo en multiples ejes simultaneamente ⇒ ocupa una neurona sola y queda aislado en la Matriz U.
- **(3,0) Finland, Italy, Sweden**: GDP ∼36200, `Pop.growth` +0,2. Bloque norte-mediterraneo desarrollado pero sin ser el top.

Vecinos en el mapa: la topologia importa

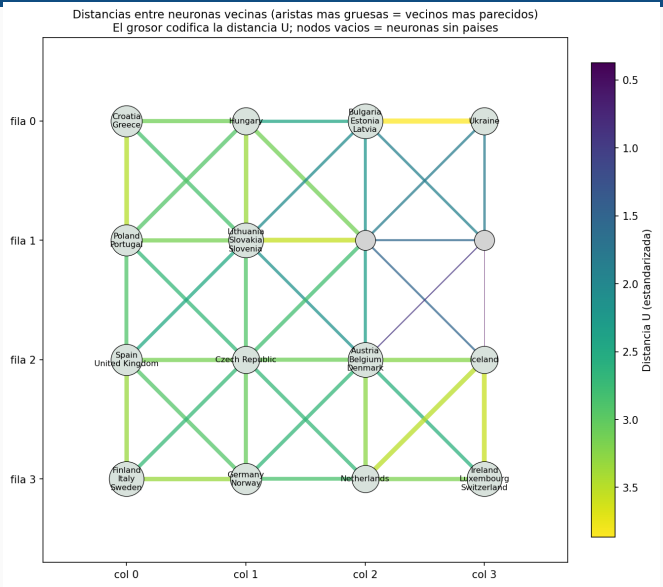

Cada arista codifica la distancia entre los pesos de neuronas vecinas:

- Aristas gruesas y oscuras: vecinos parecidos.
- Aristas finas y claras: fronteras.

Patrones que emergen:

- La fila 3 (ricos) esta unida por aristas oscuras: Switzerland-Luxembourg-Ireland fluye continuamente hacia Germany-Norway y Netherlands.
- Ucrania (0,3) tiene la arista mas clara hacia Bulgaria-Estonia-Latvia (0,2): ahi esta la frontera real.
- Las dos neuronas vacias en (1,2) y (1,3) actuan como zona buffer entre el cuadrante rico (abajo-derecha) y la zona pobre (arriba-derecha).

Interpretacion del mapa

- **Fila 3 (abajo)** — alta `GDP`, alta `Life.expect`: Finland, Italy, Sweden, Germany, Norway, Netherlands, Ireland, Luxembourg, Switzerland.
- **Fila 0 (arriba)** — baja `GDP`, alta `Inflation`, alta `Unemployment`: Croatia, Greece, Hungary, Bulgaria, Estonia, Latvia, Ukraine.
- **Columna 0 (izquierda)** — alta `Military`: Grecia, Croacia, Spain.
- **Columna 3 esquina (0,3)** — aislada por la Matriz U: Ucrania, −PIB, +inflacion extrema (8 %).

Los ejes ortogonales del SOM **coinciden con los ejes PC1 y PC2**:

- Vertical $\approx$ PC1 (desarrollo).
- Horizontal $\approx$ PC2 (crisis fiscal).

Eleccion de hiperparametros

Cinco barridos, una variable a la vez

Por que no *cualquier* configuracion sirve

- El SOM tiene varios hiperparametros que afectan de manera distinta el mapa:
  - **Tamano de grilla** k controla la resolucion: mas neuronas = ajuste mas fino pero clusters mas dispersos.
  - **Inicializacion** (muestras vs aleatorio) controla el punto de partida.
  - **Radio** $R(t)$ controla cuanta vecindad se actualiza: mucho vecindario = mapa suave; nada = k-means.
  - **Tasa de aprendizaje** $\eta(t)$ controla la magnitud de cada actualizacion.
  - **Semilla** (azar): el algoritmo es estocastico.
- Para cada uno: **fijamos los demas, variamos uno solo**, y reportamos cuatro metricas:
  - QE final: error de cuantizacion — ajuste a los datos.
  - Neuronas activas: cuantas reciben al menos un pais.
  - U mean: que tan "continuo" es el mapa.
  - U std: que tan marcadas son las fronteras entre clusters.

Barrido 1: tamano de grilla

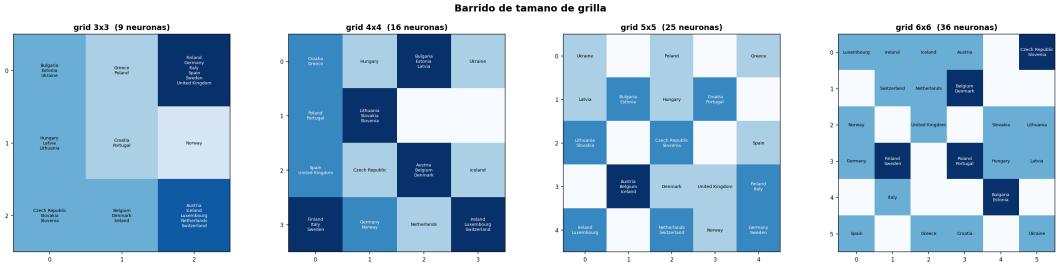

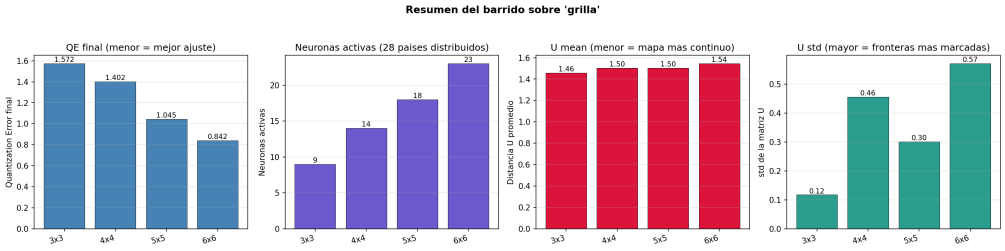

Tamano de grilla: lectura

- 3×3: 9 neuronas, todas pobladas, pero clusters forzosamente mezclados (5 paises en una sola neurona). QE alto: 1.57.
- 4×4 (elegida): 14/16 activas, clusters densos pero separados. Balance entre resolucion y poblacion.
- 5×5 **y** 6×6: QE baja drasticamente (1.05 y 0.84), *pero* 7 y 13 neuronas quedan vacias respectivamente. El mapa se sparsifica: muchos paises terminan en neuronas con un solo elemento, lo que no nos sirve para **agrupar**.
- **Regla heuristica**: $k^2 \approx N/2$ a N. Con $N = 28$, $4 \times 4 = 16$ esta en el rango optimo.

Barrido 2: inicializacion

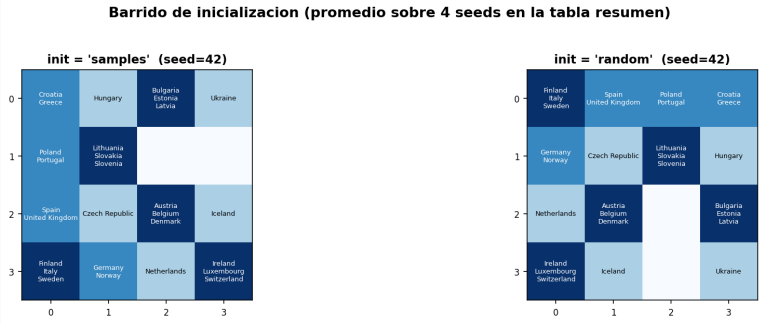

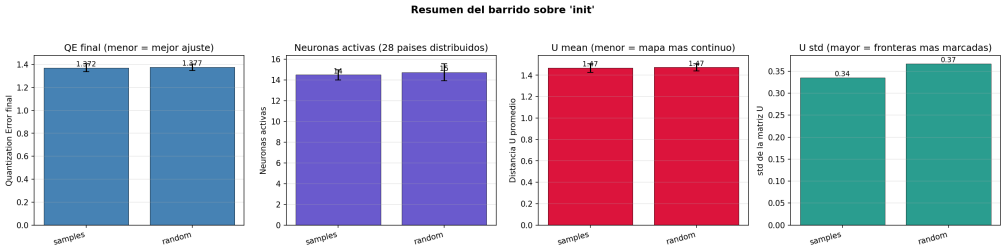

Inicializacion: las dos opciones son equivalentes

- **samples**: cada neurona arranca igual a una muestra del dataset + jitter 10^{-3}. QE final promedio: 1,37, neuronas activas: 14,5.
- **random**: cada neurona arranca uniforme en $[-1, 1]^7$. QE final promedio: 1,38, neuronas activas: 14,75.
- Diferencia despreciable entre ambas, dentro del ruido por seed.
- **Por que**: con 500 epocas y $R_0 = 2$ el SOM tiene tiempo de sobra para auto-organizarse; el punto de partida se olvida.
- Igual elegimos **samples** por convencion teorica: la convergencia inicial es mas suave y al inicio QE ya es bajo.

Barrido 3: radio del vecindario

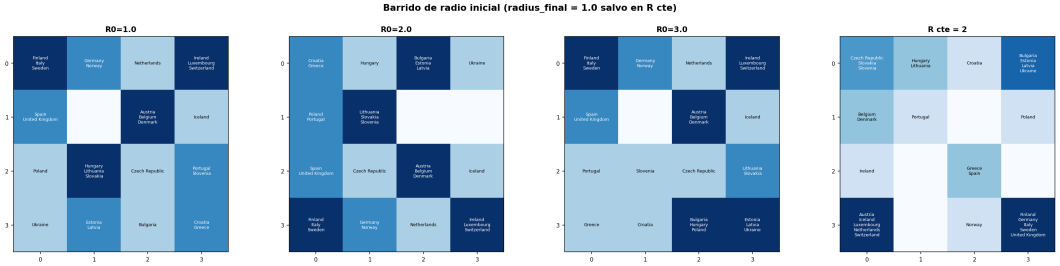

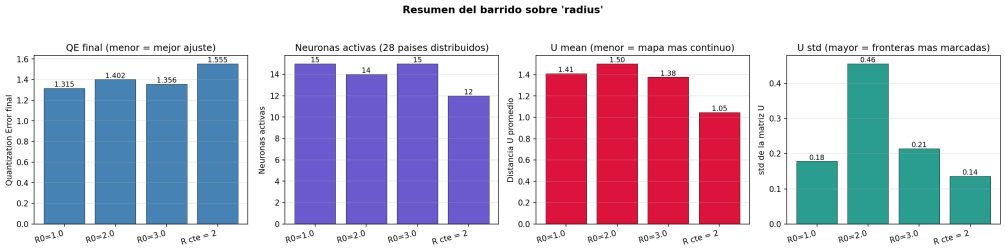

Radio: el hiperparametro mas delicado

- $R_0 = 1$ **(solo ganadora)**: el SOM degenera en k-means. No hay topologia: la posicion en la grilla es arbitraria. U std baja (0.18) porque las neuronas vecinas no se influencian.
- $R_0 = 2$ (elegida): vecindario amplio al inicio que se cierra a 1. Fronteras maximas (U std $= 0{,}46$), QE razonable (1.40).
- $R_0 = 3$: arranca con vecindario casi global. Funciona pero el cluster de ricos queda fragmentado.
- R **constante** $= 2$: nunca focaliza. U mean baja (1.05) — mapa muy suave — pero QE alto (1.56) y 4 neuronas vacias.
- **Conclusion**: schedule decreciente con $R_0 \approx k/2$ es la receta clasica y la unica que produce simultaneamente fronteras y buen ajuste.

Barrido 4: tasa de aprendizaje

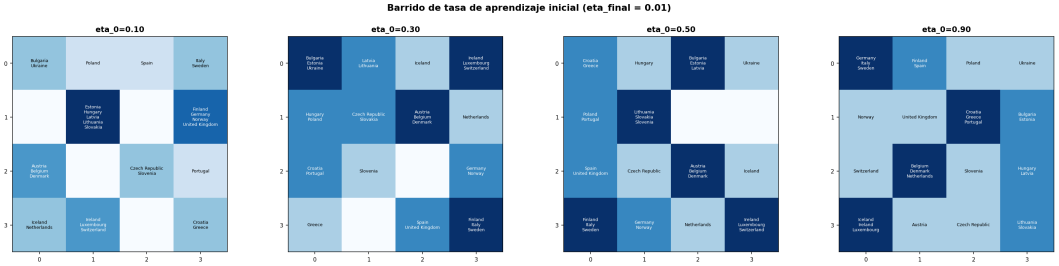

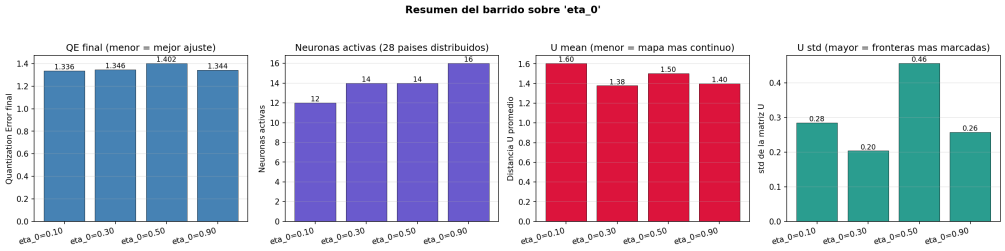

Tasa de aprendizaje: robusta

- Los cuatro valores de $\eta_0 \in \{0{,}1, 0{,}3, 0{,}5, 0{,}9\}$ producen QE final dentro de $[1{,}33, 1{,}40]$ — una franja del 5 %.
- Para η_0 chico (0.1) el mapa no termina de definirse: 4 neuronas vacias, U mean mas alta.
- Para η_0 grande (0.9) el SOM se "estira" mas, llega a 16/16 neuronas activas.
- Elegimos $\eta_0 = 0{,}5$ porque produce U std maxima (fronteras mas legibles) sin sacrificar ajuste.
- **Lectura general**: el SOM es relativamente robusto a η siempre que decaiga al final; el radio importa mucho mas.

Barrido 5: variabilidad por seed

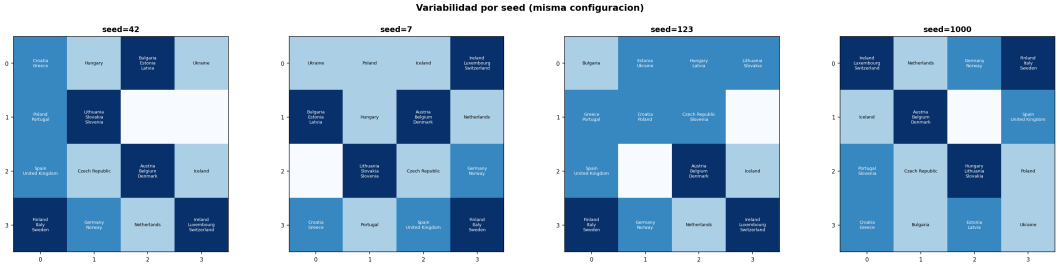

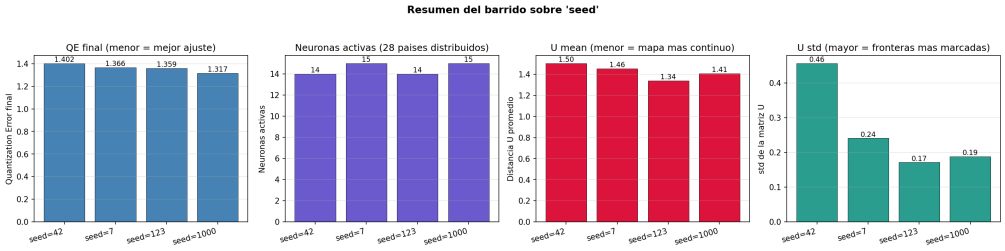

Estabilidad: el algoritmo es estocastico pero coherente

- Cuatro seeds distintos $\{42, 7, 123, 1000\}$ con la misma configuracion.
- QE final: rango $[1{,}32, 1{,}40]$ ($\sim 5\,\%$ de variacion).
- Neuronas activas: 14–15 (siempre similar).
- Los **clusters principales se conservan** en todas las corridas: el cuadrante de ricos, el outlier Ucrania, el bloque baltico/balcanico. Lo que cambia es la orientacion del mapa (rotaciones / reflexiones) — esperable porque la grilla no tiene direccion privilegiada.
- **Conclusion**: el seed afecta la presentacion visual pero no la estructura aprendida.

Configuracion final elegida

Hiperparametros entregados:

- `grid_size = 4`
- `epochs = 500`
- `eta_0 = 0.5` $\rightarrow$ `eta_final = 0.01` (lineal)
- `radius_0 = 2.0` $\rightarrow$ `radius_final = 1.0` (lineal)
- `init = "samples"`
- `seed = 42`

Justificacion:

- Grilla 4×4 esta en el sweet spot $k^2 \approx N/2$.
- Schedule lineal decreciente de η y R saca lo mejor de las dos fases (ordenamiento global y refinamiento local).
- $\eta_0 = 0{,}5$ maximiza la nitidez de las fronteras (U std).
- Resultado reproducible (seed fijo) y robusto (rango $\pm 5\,\%$ en QE entre seeds).

Conclusiones

Que aprendimos del EJ1

- **PC1 captura "desarrollo / bienestar"** — combinacion ponderada de +GDP, +Life.expect, +Pop.growth, −Inflation, −Unemployment. Explica el 46 % de la varianza.
- **Oja recupera PC1** sin resolver autovalores explicitamente: cosine similarity 0,99999943, ranking de paises identico al de la libreria. Validacion total de la teoria iterativa.
- **El SOM produce un mapa topologico consistente con PCA**: paises del bloque oeste-norte vs este-sur, con Ucrania aislada como outlier. La Matriz U evidencia que el SOM aprende fronteras de cluster, no solo prototipos.
- Las tres tecnicas convergen al mismo relato geopolitico: hay un eje principal de desarrollo y un eje secundario de crisis fiscal.

Gracias.

Codigo + figuras en el repositorio.