PCA sobre el dataset Europa

Ejercicio 1 - Aprendizaje No Supervisado

TP4 – Sistemas de Inteligencia Artificial

13 de mayo de 2026

ITBA — 2026

1. Estandarizacion: por que es necesaria

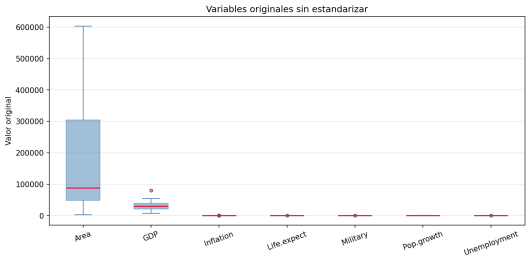

Sin estandarizar

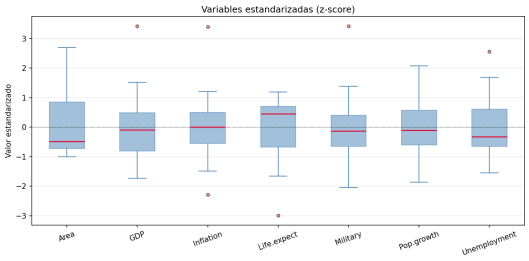

Con z-score

- Sin estandarizar, `Area` y `GDP` dominan la varianza solo por escala.
- Con *z-score*, cada variable queda con media 0 y varianza 1, y todas pasan a ser comparables.
- Por eso aplicamos PCA sobre datos estandarizados, equivalente a trabajar sobre la matriz de correlacion.

2. Estructura del dataset: hay relaciones para resumir

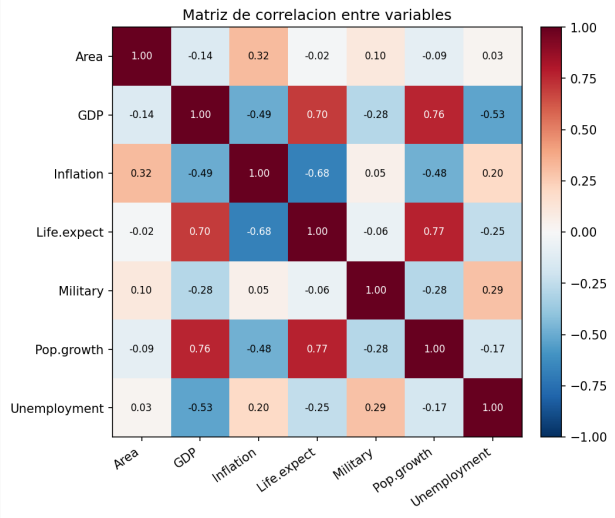

Idea clave: el dataset no es una nube uniforme en 7D. Hay variables que se mueven juntas.

- `GDP` y `Pop.growth`: $r = +0{,}76$.
- `Life.expect` y `Pop.growth`: $r = +0{,}77$.
- `GDP` y `Life.expect`: $r = +0{,}70$.
- `Inflation` y `Life.expect`: $r = -0{,}68$.

Entonces tiene sentido buscar nuevas direcciones que concentren la informacion redundante en pocas componentes.

3. Cargas de PC1 y PC2

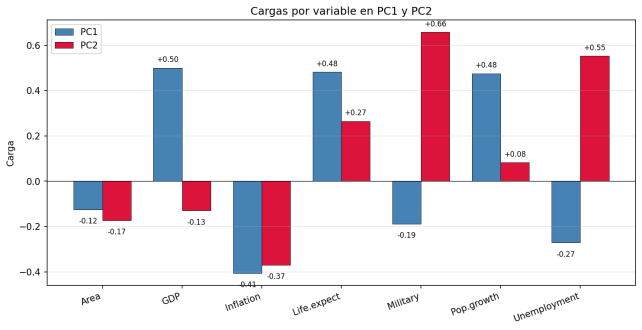

PC1 define un eje de **desarrollo**: favorece `GDP`, `Life.expect` y `Pop.growth`.

PC2 separa paises con mas **tension**: pesan fuerte `Military` y `Unemployment`.

Entre **PC1** y **PC2** explican el **63.1 %** de la varianza total.

4. Biplot PC1 vs PC2

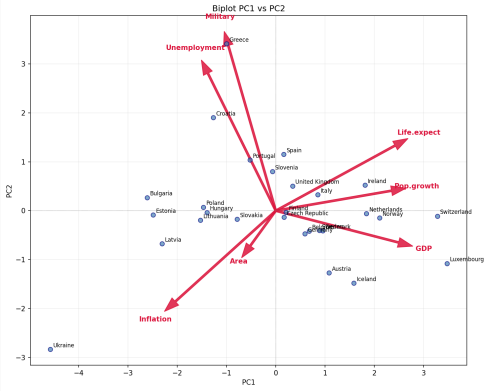

Luxembourg: queda extremo en **PC1** porque combina muy alto `GDP`, alta `Life.expect` y crecimiento poblacional positivo; por eso aparece sobre el eje de desarrollo.

Greece: sube en **PC2** porque presenta mas tension, especialmente por `Military` y `Unemployment` altos.

PCA resume el dataset en dos ejes interpretables:

desarrollo / bienestar y una dimension complementaria de tension economica.

Backup: Varianza explicada

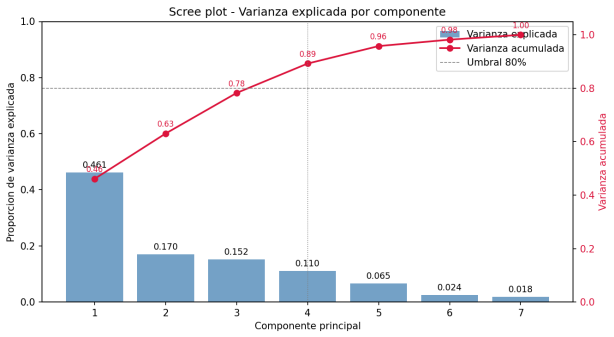

- **PC1**: 46.1 % de la varianza.
- **PC2**: 17.0 %.
- **PC3**: 15.2 %.
- **PC1 + PC2**: 63.1 %.

Lectura:

- Con dos componentes ya visualizamos gran parte de la estructura.
- Con tres componentes se llega a 78.3 %.
- Hace falta una cuarta para superar el 80 %.